

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НОВОСИБИРСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ГОСУДАРСТВЕННЫЙ
УНИВЕРСИТЕТ»

ИНСТИТУТ ИНТЕЛЛЕКТУАЛЬНОЙ РОБОТОТЕХНИКИ

Кафедра интеллектуальных систем теплофизики ИИР

Направление подготовки 09.03.03 Прикладная информатика

Направленность (профиль) Прикладной искусственный интеллект

ОТЧЕТ

о прохождении учебной практики (ознакомительной практики)

(указывается наименование практики)

Обучающегося Малюгин Юрий Иванович группы № 25946 курса 1

(Ф.И.О. полностью)

Тема задания: Кейс «Анализ тональности отзывов для улучшения клиентского сервиса»

Место прохождения практики: ФГАОУ ВО «Новосибирский национальный
исследовательский
государственный университет», Институт интеллектуальной робототехники,
кафедра интеллектуальных систем теплофизики ИИР, 630090, г. Новосибирск, ул. Пирогова,
1

Сроки прохождения практики: с 02.02.2026 г. по 27.05.2026 г.

Руководитель практики _____

(Ф.И.О. полностью, ученая степень, звание)

(подпись)

Оценка по итогам защиты отчета: _____

(неудовлетворительно, удовлетворительно, хорошо, отлично)

Отчет заслушан на заседании кафедры _____

КафИСТИИР

(наименование кафедры)

Новосибирск, 2026

СОДЕРЖАНИЕ

Определения, обозначения и сокращения.....	3
Введение.....	4
1. Краткая характеристика проекта	6
2. Выполненные работы в период практики.....	8
3. Полученные результаты и приобретенные навыки.....	10
Заключение.....	11
Список использованных источников и литературы.....	12
Приложение А. Материалы анализа данных и качества модели	13
Приложение Б. Материалы интерпретации модели.....	19

ОПРЕДЕЛЕНИЯ, ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

EDA - exploratory data analysis, разведочный анализ данных: первичная проверка корпуса, распределений, пропусков, дубликатов и базовых статистик текста.

TF-IDF - частотное представление текста, учитывающее частоту термина в документе и обратную частоту термина в корпусе.

SVD - метод понижения размерности; в проекте использовался для сжатия словесных и символьных TF-IDF признаков.

Macro-F1 - среднее значение F1-меры по классам без учета их размера; метрика удобна для сравнения качества многоклассовой классификации.

ROC-AUC OVR - площадь под ROC-кривой в схеме one-vs-rest для многоклассовой задачи.

PR-AUC - площадь под precision-recall кривой; дополнительно показывает качество при разном балансе точности и полноты.

PDP/ICE - графики частичной зависимости и индивидуальных условных зависимостей, показывающие, как изменение признака связано с прогнозом модели.

SHAP - метод оценки вклада признаков в прогноз модели на основе значений Шепли.

word_svd_* - латентные признаки, полученные после сжатия словесного TF-IDF представления методом SVD.

char_svd_* - латентные признаки, полученные после сжатия символьного TF-IDF представления методом SVD.

pos_neg_top_diff - разность между числом совпадений со словами, характерными для положительного и отрицательного классов.

num_chars - длина текста отзыва в символах.

num_negations - число отрицаний в тексте отзыва.

ВВЕДЕНИЕ

В период учебной практики была выполнена работа, связанная с проектированием и разработкой программной платформы для автоматического определения тональности русскоязычных отзывов. Практическая значимость темы определяется тем, что отзывы пользователей являются одним из наиболее доступных источников сведений о качестве товара, уровне сервиса, типовых проблемах логистики и соответствии товара ожиданиям покупателя. Для компаний электронной коммерции оперативная обработка больших массивов отзывов позволяет быстрее выявлять проблемные зоны и принимать решения на основе данных, а не отдельных субъективных примеров [4, 5].

Оформление отчета выполнялось с учетом требований нормоконтроля НГУ и общих правил подготовки отчетных документов: структуры работы, нумерации страниц, оформления таблиц, рисунков, ссылок и списка использованных источников [1-3].

Целью практики являлось выполнение полного цикла прикладного проекта машинного обучения: от разведочного анализа датасета и подготовки признаков до обучения модели, интерпретации ее решений и интеграции в пользовательское приложение. В качестве предметной области был выбран анализ отзывов о товарах категории «женская одежда и аксессуары» на основе корпуса RuReviews [10], что позволило работать с содержательно однородным и при этом достаточно большим корпусом текстов.

Объектом исследования являются русскоязычные пользовательские отзывы и программная система их обработки. Предметом исследования выступают методы автоматической классификации тональности отзывов и интерпретации решений модели машинного обучения.

Для достижения цели были поставлены следующие задачи: выполнить EDA (exploratory data analysis, разведочный анализ данных), подготовить признаковое описание текстов, обучить и сравнить несколько моделей классификации, выбрать наилучший алгоритм по качеству, реализовать backend и frontend сервиса, а также интерпретировать поведение модели с помощью PDP/ICE (графиков частичной зависимости и индивидуальных условных зависимостей) и SHAP (метода оценки вкладов признаков на основе значений Шепли). Отдельное внимание уделялось тому, чтобы система была пригодна не только для демонстрации, но и для пакетной обработки CSV-файлов с последующим просмотром, фильтрацией и ручной корректировкой результатов.

Отдельной задачей являлась проверяемость результата. Поэтому в работе фиксировались не только итоговые метрики, но и промежуточные артефакты: статистика EDA, параметры разбиения данных, настроенные гиперпараметры моделей, графики качества, feature importance, permutation importance, PDP/ICE и SHAP. Такой набор

материалов позволяет объяснить, почему выбранная модель была использована в приложении, и какие признаки действительно влияют на ее решения.

1. КРАТКАЯ ХАРАКТЕРИСТИКА ПРОЕКТА

Разработанный проект представляет собой веб-платформу для анализа тональности отзывов. Серверная часть реализована на FastAPI, клиентская часть — на React. Backend поддерживает одиночный анализ текста, пакетную обработку CSV-файлов, сохранение результатов на сервере, фильтрацию по источнику и метке класса, ручную корректировку разметки, расчет метрики maseo-F1 и выдачу агрегированных данных для визуализации. Frontend предоставляет вкладки для всех перечисленных операций и ориентирован на работу с аналитиком или исследователем.

В проекте также реализован самостоятельный ML-контур: EDA, подготовка признаков, обучение моделей CatBoost, XGBoost и LightGBM, расчет метрик качества, построение матриц ошибок, ROC- и PR-кривых, а также генерация интерпретационных графиков PDP/ICE и SHAP. Такой раздельный подход удобен на практике: обучение и исследование модели выполняются отдельно, а в приложение поставляются уже готовые runtime-артефакты.

Этап EDA включал очистку корпуса и оценку его пригодности для обучения модели. Были удалены 2679 дубликатов и один пустой текст, проверено отсутствие пропусков и утечек между train, validation и test-выборками, рассчитаны распределения классов и базовые характеристики длины отзывов. После очистки осталось 87 320 наблюдений, классы сохранили почти равномерное распределение, а средняя длина текста составила около 133 символов и 20 слов. Эти результаты использовались при выборе признаков и настройке последующего обучения.

Признаковое пространство формировалось единым образом для всех сравниваемых моделей. Оно не подбиралось отдельно под одну модель: логистическая регрессия, CatBoost, XGBoost и LightGBM обучались на одинаковой подготовленной таблице признаков. В эту таблицу вошли ручные статистические признаки, признаки лексикона, шаблонные индикаторы, признаки совпадения с частотными словами классов, а также сжатые компоненты словесного и символьного TF-IDF. Благодаря этому сравнение моделей отражало именно различие алгоритмов, а не преимущество одной модели из-за отдельного набора признаков [6].

Ручные признаки были нужны для того, чтобы модель учитывала простые, но содержательные свойства отзывов: длину текста, количество слов и предложений, число отрицаний, вопросительных и восклицательных знаков, наличие повторяющихся символов, соотношение позитивных и негативных лексических маркеров, а также выражения вроде «не рекомендую» или «не соответствует описанию». TF-IDF и SVD-компоненты дополняли эти

признаки более широким статистическим описанием текста, которое сложно полностью задать вручную.

2. ВЫПОЛНЕННЫЕ РАБОТЫ В ПЕРИОД ПРАКТИКИ

В ходе практики была разработана структура проекта и реализованы основные компоненты сервиса. Были подготовлены сценарии работы backend и frontend, формат входных данных, логика хранения результатов пакетного анализа и организация визуализации. В ML-части был реализован общий модуль формирования признаков, который использовался всеми сравниваемыми моделями. Это важно, потому что итоговый выбор лучшей по метрике модели был сделан не из-за особого набора признаков, а по результатам сравнения алгоритмов на одинаковой подготовленной выборке. Дополнительно была проверена линейная логистическая регрессия как сильный baseline.

После подготовки признаков были сформированы train, validation и test-таблицы. Для словесного TF-IDF использовалось ограничение словаря до 8000 признаков, для символьного TF-IDF - до 5000 признаков. Затем размерность этих представлений была снижена с помощью TruncatedSVD: 200 компонент для словесного уровня и 150 компонент для символьного уровня. Такой подход позволил сохранить информацию о лексике и характерных фрагментах слов, но не перегружать бустинговые модели десятками тысяч разреженных признаков [4, 6].

Для каждой бустинговой модели выполнялся подбор гиперпараметров через RandomizedSearchCV с оптимизацией макро-F1 на кросс-валидации. После подбора модели были дополнительно переобучены на полном train. Лучшие параметры XGBoost составили: `n_estimators = 900`, `learning_rate = 0.03`, `max_depth = 8`, `min_child_weight = 5`, `subsample = 1.0`, `colsample_bytree = 0.7`, `reg_alpha = 0.0`, `reg_lambda = 1.0`. Для LightGBM использовались `n_estimators = 900`, `learning_rate = 0.03`, `num_leaves = 63`, `max_depth = 10`, `min_child_samples = 40`, `subsample = 0.85`, `colsample_bytree = 0.7`, `reg_alpha = 0.5`, `reg_lambda = 0.0` [8, 9].

Был проведен анализ экспериментальных результатов по линейной логистической регрессии и трем бустинговым моделям: CatBoost, XGBoost и LightGBM. После refit на полном train наилучшее качество среди бустингов показала XGBoost-модель с `macro-F1 = 0.7418`, `accuracy = 0.7401`, `ROC-AUC OVR = 0.8932` и `PR-AUC = 0.8056`. LightGBM после refit показала близкий результат `macro-F1 = 0.7400` и использовалась для детальной интерпретации PDP/ICE и SHAP.

Дополнительно оценивались не только итоговые значения метрик, но и устойчивость признаков. Встроенная важность LightGBM показала высокий вклад SVD-компонент, а permutation importance проверяла, насколько падает макро-F1 при случайном перемешивании отдельного признака. В таблицу permutation importance был добавлен нулевой baseline, чтобы отделять признаки с реальным вкладом от признаков, эффект которых близок к случайному или отсутствует. Наиболее заметное снижение качества давали латентная словесная SVD-

компонента, длина текста, баланс позитивной и негативной лексики, латентная символьная SVD-компонента и число отрицаний.

Помимо оценки качества была выполнена содержательная интерпретация модели. Для этого использовались графики PDP/ICE и SHAP [7]. По ним было установлено, что для данного датасета ключевую роль играют признаки, связанные с балансом позитивной и негативной лексики, числом отрицаний, длиной текста, наличием шаблона «не рекомендую», а также скрытыми SVD-компонентами, кодирующими темы несоответствия описанию, качества ткани, возврата денег, продавца и доставки.

3. ПОЛУЧЕННЫЕ РЕЗУЛЬТАТЫ И ПРИОБРЕТЕННЫЕ НАВЫКИ

В результате практики был получен целостный опыт разработки прикладного проекта на стыке машинного обучения и веб-разработки. Практически были закреплены навыки проектирования структуры приложения, постановки экспериментов, сравнения моделей, интерпретации результатов, а также подготовки исследовательских ML-артефактов к использованию в прикладном сервисе.

Отдельно можно выделить навыки анализа текстовых данных: работа с русскоязычным датасетом отзывов, оценка качества разметки и баланса классов, использование метрики macro-F1 , построение признакового описания текста и объяснение поведения модели с помощью PDP/ICE и SHAP. Отдельно был закреплен навык проверки признаков: недостаточно просто получить высокую метрику, нужно понимать, какие признаки действительно влияют на решение модели и не является ли часть признакового пространства случайным шумом.

С практической точки зрения выбранный стек оказался удобным для задачи клиентской аналитики. Бустинговые модели работают с табличными признаками, быстро выполняют инференс, сохраняются в виде переносимых артефактов и позволяют применять разные способы интерпретации: встроенную важность признаков, *permutation importance*, PDP/ICE и SHAP. Поэтому результат можно использовать не только как классификатор тональности, но и как инструмент объяснения причин негативных срабатываний.

В ходе работы также были получены прикладные навыки интеграции модели в приложение: загрузка артефактов, проверка входного CSV, пакетный инференс, хранение результатов, фильтрация по меткам, ручная корректировка спорных предсказаний и расчет агрегированных показателей для интерфейса. Такая связка ML-экспериментов и сервиса делает проект ближе к реальной задаче клиентского сервиса, где важны не только метрики, но и удобство последующей работы с результатами.

ЗАКЛЮЧЕНИЕ

По итогам учебной практики была разработана платформа анализа тональности русскоязычных отзывов, объединяющая машинное обучение и веб-интерфейс для прикладной работы с результатами. Поставленные задачи были решены: выполнен EDA датасета, подготовлены признаки, обучены и сравнены несколько моделей классификации, включая логистическую регрессию, CatBoost, XGBoost и LightGBM. После refit лучшей по точечной метрике стала конфигурация XGBoost, а близкая по качеству LightGBM-модель была использована для интерпретации признаков и подготовки выводов о том, какие языковые сигналы сильнее всего влияют на решение модели.

Практика показала, что интерпретируемость является не вспомогательным, а центральным элементом качественного ML-проекта. Использование PDP и SHAP позволило не только объяснить ответы модели, но и связать их с конкретными проблемами предметной области: несоответствием товара описанию, качеством материалов, вопросами доставки и возврата средств. Полученный результат может служить основой как для дальнейшего развития приложения, так и для подготовки научной публикации.

Главный итог состоит в том, что модели сравнивались на едином признаковом пространстве, а не за счет отдельного подбора признаков под одну библиотеку. Это делает вывод о качестве более корректным: XGBoost после refit показал лучший macro-F1, логистическая регрессия оказалась сильным baseline, а LightGBM сохранила практическую ценность как близкая по качеству и удобная для интерпретации модель.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ И ЛИТЕРАТУРЫ

1. ГОСТ 7.32-2017. СИБИД. Отчет о научно-исследовательской работе. Структура и правила оформления [Электронный ресурс]. URL: <https://docs.cntd.ru/document/1200157208>
2. ГОСТ Р 7.0.5-2008. СИБИД. Библиографическая ссылка. Общие требования и правила составления [Электронный ресурс]. URL: https://www.nntu.ru/frontend/web/ngtu/files/org_structura/library/resurvsy/gost_r_7_0_5_2008.pdf
3. НГУ. Нормоконтроль: направление подготовки 09.03.03 Прикладная информатика, направленность «Прикладной искусственный интеллект» : презентация. Новосибирск, 2026.
4. Двойникова А. А., Карпов А. А. Аналитический обзор подходов к распознаванию тональности русскоязычных текстовых данных // Информационно-управляющие системы. 2020. № 4. С. 20-30. DOI: 10.31799/1684-8853-2020-4-20-30.
5. Самигулин Т. Р., Джурабаев А. Э. У. Анализ тональности текста методами машинного обучения // Научный результат. Информационные технологии. 2021. Т. 6. № 1. С. 55-62. DOI: 10.18413/2518-1092-2021-6-1-0-7.
6. Воронцов К. В. Машинное обучение : курс лекций [Электронный ресурс]. URL: [https://www.machinelearning.ru/wiki/index.php?title=Машинное_обучение_\(курс_лекций,_К.В.Воронцов\)](https://www.machinelearning.ru/wiki/index.php?title=Машинное_обучение_(курс_лекций,_К.В.Воронцов))
7. Попов Н. В., Шевская Н. В. Методы объяснимого искусственного интеллекта на основе анализа пространства признаков // Компьютерные технологии и системы. 2021. С. 298-300. URL: <https://cts.etu.ru/assets/files/2021/cts21/papers/298-300.pdf>
8. Яндекс Образование. Градиентный бустинг [Электронный ресурс]. URL: <https://education.yandex.ru/handbook/ml/article/gradientnyj-busting>
9. Яндекс. CatBoost — библиотека градиентного бустинга на деревьях решений [Электронный ресурс]. URL: <https://yandex.ru/dev/catboost/?lang=ru>
10. RuReviews: An Automatically Annotated Sentiment Analysis Dataset for Product Reviews in Russian [Электронный ресурс]. URL: <https://github.com/sismetanin/rureviews>

ПРИЛОЖЕНИЕ А. МАТЕРИАЛЫ АНАЛИЗА ДАННЫХ И КАЧЕСТВА МОДЕЛИ

Таблица А.1 - Сравнение качества моделей на тестовой выборке

Модель	Accuracy	Macro-F1	ROC-AUC OVR	PR-AUC
Logistic Regression	0.7383	0.7398	0.8935	0.8033
CatBoost full refit	0.7342	0.7357	0.8917	0.8024
XGBoost full refit	0.7401	0.7418	0.8932	0.8056
LightGBM full refit	0.7381	0.7400	0.8938	0.8070

Для лучшей по точечной метрике модели XGBoost full refit по классам получены следующие F1-показатели: негативный класс — 0.72, нейтральный — 0.65, позитивный — 0.85. Наиболее сложным оказался нейтральный класс, что типично для задач анализа пользовательских отзывов.

На рисунке А.1 показаны основные результаты EDA: проверка распределения классов, статистика длины текстов и общая пригодность корпуса к обучению. Этот этап подтвердил, что после удаления дубликатов данные остаются сбалансированными и могут использоваться без искусственного перевешивания классов.




Рисунок А.1 - Обзорные результаты EDA по корпусу отзывов

На рисунках А.2-А.4 приведены диагностические графики качества XGBoost full refit. Матрица ошибок показывает, что основная сложность связана с нейтральным классом. ROC- и PR-кривые дополняют ассигасу и масго-F1, так как показывают поведение модели при разных порогах и для каждого класса.




Рисунок А.2 - Матрица ошибок XGBoost full refit на тестовой выборке




Рисунок А.3 - ROC-кривые XGBoost full refit в схеме one-vs-rest




Рисунок А.4 - Precision-recall кривые XGBoost full refit

На рисунках А.5 и А.6 показаны два разных взгляда на важность признаков. Встроенная важность отражает вклад признаков в структуру деревьев, а permutation importance показывает падение макро-F1 после перемешивания признака. Совпадение важных признаков в этих подходах усиливает доверие к интерпретации модели.




Рисунок А.5 - Встроенная важность признаков LightGBM




Рисунок А.6 - Permutation importance по снижению макро-F1

ПРИЛОЖЕНИЕ Б. МАТЕРИАЛЫ ИНТЕРПРЕТАЦИИ МОДЕЛИ

Графики PDP/ICE показывают, как модель меняет вероятность классов при изменении конкретного признака. Рост числа отрицаний и наличие шаблона «не рекомендую» повышают вероятность негативного класса, а признак `pos_neg_top_diff` отражает баланс позитивной и негативной лексики.




Рисунок Б.1 - График PDP/ICE для признака `num_negations` в модели LightGBM




Рисунок Б.2 - График PDP/ICE для признака `pos_neg_top_diff` в модели LightGBM




Рисунок Б.3 - График PDP/ICE для признака `has_not_recommend` в модели LightGBM

SHAP-графики показывают распределение вкладов признаков по отдельным объектам. Для отрицательного класса важны признаки, связанные с негативной лексикой, отрицаниями и латентными компонентами несоответствия товара описанию. Для положительного класса заметен обратный эффект признаков, связанных с позитивной лексикой и отсутствием явных жалоб.




Рисунок Б.4 - SHAP beeswarm для отрицательного класса




Рисунок Б.5 - SHAP beeswarm для положительного класса