

ИНТЕРПРЕТИРУЕМАЯ БИЗНЕС-АНАЛИТИКА РУССКОЯЗЫЧНЫХ ОТЗЫВОВ ЭЛЕКТРОННОЙ КОММЕРЦИИ НА ОСНОВЕ ГРАДИЕНТНОГО БУСТИНГА, SHAP И PDP

Малюгин Юрий Иванович

*Новосибирский национальный исследовательский государственный университет,
Новосибирск, Россия*

Аннотация.

Работа посвящена интерпретируемому анализу тональности русскоязычных отзывов электронной коммерции. Главная задача состоит не только в классификации отзывов на отрицательные, нейтральные и положительные, но и в извлечении из модели признаков, которые можно использовать как бизнес-сигналы о клиентском опыте. На сбалансированном корпусе RuReviews по категории женской одежды и аксессуаров построено признаковое пространство из 433 признаков: ручные статистические и лексические признаки, 200 SVD-компонент словесного TF-IDF и 150 SVD-компонент символьного TF-IDF. Для контроля качества сопоставлены логистическая регрессия на тех же признаках, CatBoost, XGBoost и LightGBM. Логистическая регрессия при сопоставимой схеме обучения показала $\text{macro-F1} = 0.7398$, а лучший после refit бустинг, XGBoost, получил $\text{macro-F1} = 0.7418$, $\text{ROC-AUC OVR} = 0.8932$ и $\text{PR-AUC} = 0.8056$. LightGBM после refit показала близкий результат $\text{macro-F1} = 0.7400$ и использовалась для детальной SHAP/PDP-интерпретации. Поэтому вклад работы формулируется не как достижение максимальной метрики, а как воспроизводимый способ превратить модель тональности в объяснимую аналитику отзывов. С помощью feature importance, permutation importance, SHAP и PDP/ICE показано, что наиболее устойчивые сигналы связаны с несоответствием товара описанию и фотографии, размером, качеством ткани и швов, доставкой, возвратом денег, отрицаниями и явной фразой «не рекомендую». Полученные результаты демонстрируют, что градиентный бустинг полезен для бизнеса как интерпретируемая модель, позволяющая выявлять клиентские pain points в предметной категории.

Ключевые слова: анализ тональности, электронная коммерция, клиентский опыт, русскоязычные отзывы, градиентный бустинг, LightGBM, SHAP, PDP, permutation importance, TF-IDF, SVD.

INTERPRETABLE BUSINESS ANALYTICS OF RUSSIAN E-COMMERCE REVIEWS BASED ON GRADIENT BOOSTING, SHAP AND PDP

Abstract.

The paper studies sentiment analysis of Russian e-commerce reviews not only as a multiclass text classification task, but also as a source of interpretable business signals about customer experience. Using the RuReviews subset for women's clothing and accessories, we construct a 433-dimensional feature space that combines handcrafted statistical and lexical features, 200 word-level TF-IDF/SVD components and 150 character-level TF-IDF/SVD components. Logistic regression on the same features, CatBoost, XGBoost and LightGBM are compared. The logistic baseline reaches macro-F1 = 0.7398 under the same training-subset scheme, while XGBoost is the best full-refit boosting model with macro-F1 = 0.7418, ROC-AUC OVR = 0.8932 and PR-AUC = 0.8056. LightGBM reaches a close macro-F1 = 0.7400 and is used for detailed SHAP/PDP interpretation. Therefore, the contribution is not claimed as a new state-of-the-art classifier, but as a reproducible interpretable pipeline for turning review classification into business analytics. Feature importance, permutation importance, SHAP and PDP/ICE consistently indicate customer pain points related to product-description mismatch, size, fabric and sewing quality, delivery, refunds, negations and explicit non-recommendation phrases.

Keywords: sentiment analysis, e-commerce, customer experience, Russian reviews, gradient boosting, LightGBM, SHAP, PDP, permutation importance, TF-IDF, SVD.

1. Введение

Отзывы покупателей в электронной коммерции являются не только текстовой обратной связью, но и массивом операционных данных о качестве товара, соответствии фотографии и описанию, доставке, упаковке, возвратах и готовности рекомендовать покупку. Для управления товарной категорией одной метки тональности недостаточно: бизнесу важно понимать, почему отзыв оказался отрицательным или положительным и какие повторяющиеся причины стоят за изменением клиентского опыта.

Существующие исследования анализа тональности [6, 7] часто оценивают качество модели только по итоговой метрике. Такой подход полезен для сравнения алгоритмов, но хуже отвечает на прикладной вопрос: какие темы в отзывах реально влияют на решения модели и могут быть преобразованы в управленческие действия. Для категории одежды такими сигналами могут быть размер, посадка, ткань, швы, соответствие фото, скорость доставки и ситуации возврата денег.

В этой работе используется более узкая постановка: не предложить новый алгоритм классификации, а показать, как градиентный бустинг [1, 3] и методы интерпретации [2] могут работать как практический инструмент бизнес-аналитики русскоязычных отзывов.

Новизна носит прикладной характер: для одной товарной категории строится полный воспроизводимый конвейер от признаков и подбора моделей до сопоставления нескольких типов важности признаков, расшифровки SVD-компонент и интерпретации SHAP/PDP в терминах клиентских проблем.

Цель исследования - проверить, какие текстовые и латентные признаки оказываются значимыми для определения тональности отзывов и как эти признаки можно интерпретировать для клиентского сервиса. Для этого решаются четыре задачи: сформировать гибридное признаковое пространство, сравнить линейный baseline и три модели градиентного бустинга, проверить устойчивость признаков через permutation importance и объяснить поведение интерпретируемой бустинговой модели с помощью SHAP и PDP/ICE [2].

2. Материалы и методы

2.1. Данные и контроль качества корпуса

Исходный корпус основан на RuReviews [4, 5] - датасете русскоязычных отзывов о товарах, автоматически собранном и размеченном по тональности. В проекте использован сбалансированный поднабор категории «женская одежда и аксессуары»: по 30 000 отзывов для отрицательного, нейтрального и положительного классов. На этапе EDA отдельно проверялись пустые тексты, дубликаты, распределение длин и возможные пересечения между выборками. Для сопоставимости моделей в итоговых экспериментах использовался фиксированный стратифицированный split 72 000 / 18 000, где в тестовой части содержится по 6 000 отзывов каждого класса.

Таблица 1 - Характеристики данных и экспериментального split

Параметр	Значение
Предметная область	женская одежда и аксессуары
Классы	negative / neutral / positive
Исходный сбалансированный корпус	90 000 отзывов
Train / test	72 000 / 18 000
Поддержка классов в test	по 6 000 отзывов
Средняя длина текста по EDA	133.24 символа
Среднее число слов по EDA	20.50
Зафиксированный random_state	42

2.2. Формирование признакового пространства

Признаки строились так, чтобы модель видела не только отдельные слова, но и структуру короткого отзыва: длину текста, пунктуацию, отрицания, эмоциональные маркеры, шаблонные фразы, лексический баланс и устойчивые словесные или символичные сочетания. Всего использовались 433 признака: 83 ручных признака, 200 компонент словесного TF-IDF/SVD и 150 компонент символического TF-IDF/SVD.

Таблица 2 - Группы признаков

Группа признаков	Количество	Содержательный смысл
Статистические признаки	часть из 83	длина текста, число слов, знаки препинания, заглавные буквы, повторы символов
Лексические и шаблонные признаки	часть из 83	отрицания, интенсификаторы, слова доставки, качества, размера, возврата, фразы «не рекомендую»
SVD-компоненты словесного TF-IDF	200	латентные темы на уровне слов и фраз: размер, качество, доставка, возврат, соответствие описанию
SVD-компоненты символьного TF-IDF	150	фрагменты слов, морфологические варианты, опечатки и короткие устойчивые формы

Таблица 3 - Параметры TF-IDF и SVD

Этап	Параметры
Word TF-IDF	lowercase=True; ngram_range=(1, 3); min_df=7; max_df=0.95; max_features=8000; sublinear_tf=True
Char TF-IDF	analyzer=char_wb; ngram_range=(3, 7); min_df=7; max_df=0.95; max_features=5000; sublinear_tf=True
Word SVD	TruncatedSVD(n_components=200, random_state=42), fit только на train
Char SVD	TruncatedSVD(n_components=150, random_state=42), fit только на train

SVD-компоненты интерпретировались не как отдельные слова, а как латентные оси.

Их смысл оценивался по словам и n-граммам с наибольшими по модулю весами в компоненте. Поэтому выводы по SVD в статье сформулированы осторожно: компонент word_svd_3 не означает одно конкретное слово, а указывает на группу совместно встречающихся сигналов, связанных с несоответствием ожиданиям.

2.3. Модели, подбор параметров и интерпретация

В качестве контрольной модели обучалась логистическая регрессия на тех же 433 признаках. Для сопоставимости с сохраненными бустинговыми моделями финальная контрольная оценка считалась на той же схеме с внутренним validation-разделением train. Для основных экспериментов использовались CatBoost, XGBoost и LightGBM [1, 3]. Гиперпараметры бустингов подбирались через RandomizedSearchCV: 20 случайных комбинаций, 3-fold cross-validation, целевая метрика macro-F1, random_state=42. Такой подбор нужен не для доказательства абсолютного превосходства одного алгоритма, а для честного сравнения трех бустингов в одинаковом признаковом пространстве.

Таблица 4 - Итоговые настройки моделей

Модель	Ключевые настройки
Logistic Regression	StandardScaler; solver=lbfgs; max_iter=1000; random_state=42
CatBoost	depth=6; iterations=1200; learning_rate=0.07; l2_leaf_reg=1
XGBoost	n_estimators=900; learning_rate=0.03; max_depth=8; min_child_weight=5; subsample=1.0; colsample_bytree=0.7
LightGBM	n_estimators=900; learning_rate=0.03; num_leaves=63; max_depth=10; min_child_samples=40; subsample=0.85; colsample_bytree=0.7; reg_alpha=0.5; reg_lambda=0.0

Интерпретация проводилась несколькими независимыми способами. Встроенная feature importance показывает, какие признаки часто используются деревьями. Permutation importance проверяет, насколько падает макро-F1 после случайного перемешивания одного признака; для контроля добавлен случайный baseline-признак. SHAP показывает локальный вклад признаков в решение модели по каждому классу на выборке из 300 объектов. PDP/ICE показывает, как изменение выбранного признака связано с вероятностями классов на выборке из 3000 объектов. Различие методов принципиально: SHAP отвечает «что повлияло на конкретное предсказание», PDP - «как меняется средняя реакция модели при изменении признака», а permutation importance - «насколько признак нужен для качества».

3. Результаты

3.1. Качество классификации и устойчивость выводов

Таблица 5 - Качество моделей на тестовой выборке

Модель	Accuracy	Precision macro	Recall macro	Macro-F1	95% CI Macro-F1	ROC-AUC OVR	PR-AUC
Logistic Regression	0.7383	0.7426	0.7383	0.7398	[0.7332; 0.7463]	0.8935	0.8033
CatBoost full refit	0.7342	0.7385	0.7342	0.7357	[0.7298; 0.7420]	0.8917	0.8024
XGBoost full refit	0.7401	0.7450	0.7401	0.7418	[0.7352; 0.7477]	0.8932	0.8056
LightGBM full refit	0.7381	0.7433	0.7381	0.7400	[0.7338; 0.7462]	0.8938	0.8070

Сравнение показывает две важные вещи. Во-первых, refit на полном train действительно улучшил бустинги: XGBoost вырос до макро-F1 = 0.7418, а LightGBM - до 0.7400. Поэтому после refit лучший бустинг уже немного превосходит логистическую регрессию с макро-F1 = 0.7398. Во-вторых, bootstrap-интервалы моделей все равно пересекаются, поэтому разницу нельзя трактовать как сильное статистически доказанное превосходство. Практический вывод остается более осторожным: бустинг дает качество на

уровне сильного линейного baseline, но дополнительно поддерживает нелинейные зависимости и удобную интерпретацию через деревья, SHAP и PDP/ICE.

По отчету классификации XGBoost full refit хуже всего распознает нейтральный класс: F1 = 0.65 против 0.72 для отрицательного и 0.85 для положительного. Это ожидаемо для отзывов: нейтральные тексты часто содержат фактическое описание доставки, размера или качества без сильной эмоциональной оценки, из-за чего они оказываются ближе и к слабому позитиву, и к слабому негативу.




Рисунок 1. Матрица ошибок XGBoost full refit

3.2. Важность признаков и permutation importance




Рисунок 2. Встроенная важность признаков LightGBM




Рисунок 3. Permutation importance по снижению макро-F1

Таблица 6 - Ключевые признаки по permutation importance

Признак	Падение макро-F1	Содержательная интерпретация
word_svd_3	0.0087	несоответствие описанию, размеру, фото и цвету
num_chars	0.0057	длина и информативность отзыва
pos_neg_top_diff	0.0057	баланс позитивных и негативных маркеров
char_svd_8	0.0046	доставка и противопоставление позитивной лексики
num_negations	0.0040	отрицания в жалобах и отказах
char_svd_1	0.0037	возврат денег и проблемы с качеством
word_svd_22	0.0030	получение заказа, возврат, описание и рекомендации
char_svd_4	0.0028	продавец, доставка, качество и размер
word_svd_6	0.0028	качество ткани, синтетика, нитки, швы
exclaims_per_word	0.0028	эмоциональная насыщенность коротких отзывов

Встроенная важность и permutation importance не обязаны совпадать. Встроенная важность может высоко оценивать признак, который часто используется в деревьях, но не

всегда критичен для итоговой macro-F1. Permutation importance строже: она проверяет, что произойдет с качеством, если связь между признаком и целевой переменной разрушить. Поэтому особое значение имеют признаки, которые повторяются в нескольких списках: word_svd_3, pos_neg_top_diff, num_negations, char_svd_8 и word_svd_6. Случайный baseline-признак не дает снижения качества, что подтверждает, что верхние позиции не являются техническим шумом.

3.3. Расшифровка SVD-компонент

Таблица 7 - Содержательная интерпретация ключевых SVD-компонент

Компонента	Характерные сигналы	Осторожная интерпретация
word_svd_3	«не соответствует», «размер не соответствует», «описанию», «фото», «цвет», «на фото»	ось соответствия ожиданиям: описание, фотография, цвет и размер
word_svd_6	«качество», «не очень», «плохое», «ужасное», «синтетика», «нити», «торчат»	качество материала и исполнения
word_svd_22	«быстро», «получила», «не пришел», «деньги не вернули», «рекомендую»	доставка, получение заказа, возврат денег и рекомендация
char_svd_1	фрагменты «верну», «вернул», «деньги», а также фрагменты слов о размере и качестве	возврат денег и конфликтные ситуации после покупки
char_svd_8	фрагменты «достав», «отлич», «спасибо»	противопоставление доставки и позитивной благодарственной лексики
char_svd_34	фрагменты «супер», «спор», «открыла спор»	полярность между явной похвалой и спорной ситуацией

SVD-компоненты получились именно такими не потому, что им заранее задали смысл, а потому что в корпусе коротких отзывов повторяются устойчивые группы слов. Для одежды часто повторяются жалобы на размер, ткань и соответствие фото, а для сервиса - доставка, спор и возврат денег. TruncatedSVD сжимает TF-IDF-пространство так, что эти совместные паттерны становятся отдельными латентными координатами. Поэтому интерпретация SVD полезна, но не является причинным доказательством: ее нужно подтверждать permutation importance, SHAP и содержательным чтением примеров отзывов.

3.4. PDP/ICE: реакция модели на изменение признаков

PDP/ICE-графики показывают, как меняются вероятности классов при движении по выбранному признаку. Это особенно важно для бизнес-интерпретации: можно увидеть не только факт важности признака, но и направление эффекта. Для ручных признаков трактовка ближе к прямой: больше отрицаний или более выраженный дисбаланс негативных слов повышает вероятность отрицательного класса. Для SVD-компонент трактовка сложнее: движение по оси означает смещение текста к группе слов и фрагментов, а не добавление одного слова.




Рисунок 4. PDP/ICE для признака pos_neg_top_diff




Рисунок 5. PDP/ICE для признака num_negations




Рисунок 6. PDP/ICE для признака has_not_recommend




Рисунок 7. PDP/ICE для признака num_chars

Для pos_neg_top_diff отрицательные значения соответствуют преобладанию негативной лексики и повышают вероятность отрицательного класса. Для num_negations рост числа отрицаний также связан с усилением негативного сигнала, но эффект не является строго линейным: после нескольких отрицаний модель часто уже уверена в негативной оценке. Признак has_not_recommend полезен как явный бизнес-сигнал: фраза «не

рекомендую» не просто ухудшает тональность, а указывает на риск отказа от повторной покупки. Длина текста работает иначе: длинные отзывы чаще содержат подробности о доставке, размере или качестве, поэтому она помогает модели отличать информативные жалобы от коротких эмоциональных реакций.




Рисунок 8. PDP/ICE для латентной компоненты word_svd_3




Рисунок 9. PDP/ICE для латентной компоненты word_svd_6




Рисунок 10. PDP/ICE для латентной компоненты char_svd_8

Для SVD-компонент PDP/ICE показывает, что модель реагирует не на отдельные слова, а на движение текста вдоль латентной темы. word_svd_3 связан с несоответствием ожиданиям: размер, фото, цвет и описание. word_svd_6 отражает качество материала и исполнения: синтетика, плохая ткань, торчащие нитки. char_svd_8 дополняет словесные признаки за счет фрагментов слов, что важно для русскоязычных отзывов с опечатками, сокращениями и разными формами одних и тех же слов.

3.5. SHAP-анализ по классам

SHAP-графики дополняют PDP тем, что показывают вклад признаков в конкретные предсказания и отдельно для каждого класса. В отрицательном классе наиболее заметны `pos_neg_top_diff`, `word_svd_3`, `char_svd_1` и `num_negations`: модель связывает негатив не только с общим лексическим балансом, но и с конкретными клиентскими проблемами. В положительном классе важны признаки соответствия ожиданиям, благодарственная лексика, быстрая доставка и отсутствие жалоб. Нейтральный класс остается наиболее сложным: его SHAP-профиль состоит из смешанных описательных сигналов, где текст может быть информативным, но не иметь сильной эмоциональной полярности.




Рисунок 11. SHAP beeswarm для отрицательного класса




Рисунок 12. SHAP beeswarm для нейтрального класса




Рисунок 13. SHAP beeswarm для положительного класса

4. Обсуждение

Сравнение с линейной baseline-моделью делает вывод статьи более честным: бустинг не является единственным способом классификации таких отзывов, но после refit на полном train лучший бустинг XGBoost слегка превысил baseline по macro-F1. При сильных TF-IDF/SVD-признаках линейная модель все равно остается очень конкурентной. Однако для задачи бизнес-аналитики важны не только проценты macro-F1. LightGBM позволяет анализировать нелинейные пороги, взаимодействие признаков и устойчивость сигналов несколькими независимыми методами интерпретации.

Главный прикладной результат состоит в том, что модель выделяет не абстрактную «позитивность» или «негативность», а повторяющиеся группы клиентских проблем. Первая

группа - несоответствие ожиданиям: размер, цвет, фото и описание. Вторая - качество товара: ткань, синтетика, нитки, швы и общая оценка материала. Третья - логистика: доставка, неполучение заказа и длительное ожидание. Четвертая - постпокупочный конфликт: спор, возврат денег и явный отказ рекомендовать товар. Именно эти группы полезны для бизнеса: они могут быть превращены в отчеты для категорийного менеджмента, контроля поставщиков и клиентского сервиса.

Ограничения исследования также существенны. Во-первых, данные относятся только к одной товарной категории, поэтому выводы нельзя напрямую переносить на электронику, продукты питания или услуги. Во-вторых, разница между бустинговыми моделями мала и bootstrap-интервалы пересекаются, поэтому XGBoost корректно называть лучшим только по точечной оценке после refit, а не статистически доказанным лидером. В-третьих, SVD-компоненты требуют осторожной интерпретации: они являются латентными осями, а не понятными ручными признаками. В-четвертых, в работе не проверялись трансформерные модели типа RuBERT, поэтому статья не претендует на сравнение с современными нейросетевыми решениями по максимальному качеству.

5. Заключение

В работе показано, что анализ тональности отзывов можно использовать как инструмент объяснимой бизнес-аналитики, а не только как задачу автоматической разметки текста. На корпусе русскоязычных отзывов о женской одежде и аксессуарах построено гибридное признаковое пространство, обучены линейный baseline и три модели градиентного бустинга. После refit на полном train лучшую точечную метрику среди бустингов показал XGBoost, а близкая по качеству LightGBM-модель подробно интерпретирована через feature importance, permutation importance, SHAP и PDP/ICE.

Подробный анализ признаков показывает, что для клиентов наиболее важны не только общие эмоциональные слова, но и конкретные товарные и сервисные аспекты: соответствие описанию и фотографии, размер, качество ткани и швов, доставка, возврат денег и явное нежелание рекомендовать товар. Именно в этом состоит практическая ценность бустингового подхода: он дает достаточно сильную классификацию и одновременно позволяет объяснить, какие клиентские pain points стоят за решениями модели. Дальнейшая работа должна включать ручную валидацию выделенных аспектов, проверку на других категориях и сравнение с трансформерными моделями.

Список литературы

1. Friedman J. H. Greedy Function Approximation: A Gradient Boosting Machine // *Annals of Statistics*. 2001. Vol. 29. No. 5. P. 1189-1232.
2. Lundberg S. M., Lee S.-I. A Unified Approach to Interpreting Model Predictions // *Advances in Neural Information Processing Systems*. 2017. Vol. 30. P. 4765-4774.
3. Ke G., Meng Q., Finley T. et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree // *Advances in Neural Information Processing Systems*. 2017. Vol. 30.
4. Smetanin S., Komarov M. Sentiment Analysis of Product Reviews in Russian using Convolutional Neural Networks // *2019 IEEE 21st Conference on Business Informatics (CBI)*. 2019. P. 482-486. DOI: 10.1109/CBI.2019.00062.
5. RuReviews: An Automatically Annotated Sentiment Analysis Dataset for Product Reviews in Russian [Электронный ресурс]. URL: <https://github.com/sismetanin/rureviews>.
6. Двойникова А. А., Карпов А. А. Аналитический обзор подходов к распознаванию тональности русскоязычных текстовых данных // *Информационно-управляющие системы*. 2020. № 4. С. 20-30. DOI: 10.31799/1684-8853-2020-4-20-30.
7. Самигулин Т. Р., Джурабаев А. Э. У. Анализ тональности текста методами машинного обучения // *Научный результат. Информационные технологии*. 2021. Т. 6. № 1. С. 55-62. DOI: 10.18413/2518-1092-2021-6-1-0-7.
8. Mokgwatjane K., Paepae T. An explainable ensemble machine learning approach for multi-domain, multiclass sentiment analysis in Amazon product reviews // *Machine Learning with Applications*. 2026. Vol. 23. Art. 100825. DOI: 10.1016/j.mlwa.2025.100825.
9. Davoodi L., Mezei J., Heikkilä M. Aspect-based sentiment classification of user reviews to understand customer satisfaction of e-commerce platforms // *Electronic Commerce Research*. 2026. Vol. 26. P. 1417-1459. DOI: 10.1007/s10660-025-09948-4.